

표 하나를 계속 고쳐 쓴 며칠

★ 핵심 명제

모든 ML 기법 =
 $X(n, p)$ 행렬 · $y(n, 1)$ 벡터에
가하는 연산이다

(n, p) : n = 행(샘플 수), p = 열(변수 수)

(n, p) 표기 — 이 텍스트 전체의 척추

이 장의 두 가지 약속

표기와 읽는 법을 먼저 정한다

관통하는 표기	(n, p) 표기로 모양 변화를 매 장마다 표시한다
읽는 법	기법 이름이 아니라 행·열·값에 무엇을 했는지로 읽는다

다음 장 → 2. 전 과정 한 장 요약

전 과정 한 장 요약

2 / 12

★ 핵심

기법을 뺀 나머지 전부가 데이터 조작이다

표 한 장의 모양 (n, p) 이
여덟 단계를 거치며 바뀐다.
오른쪽 표에서 변화를 따라간다.

⚠ 기법은 이 사술의 한 칸일 뿐,
나머지 일곱은 모두 데이터 조작이다.

단계	무엇을 만지나	모양 변화
현상→표	개체=행, 속성=열	$\emptyset \rightarrow (n, p+1)$
X / y 분리	목표 열을 떼어낸다	$\rightarrow X(n, p) + y(n, 1)$
정제	결손·이상·중복 값	$(n, p) \rightarrow (n', p')$
분할	행을 나눈다	$\rightarrow$ 훈련 + 시험
변환	값의 척도를 바꾼다	열 유지 또는 증가
축소	열을 줄이거나 행을 묶는다	$(n, p) \rightarrow (n, d)$
기법	함수를 학습한다	$X \rightarrow f \rightarrow \hat{y}$
평가	두 벡터를 비교한다	$(y, \hat{y}) \rightarrow$ 스칼라

사람들이 머신러닝이라 부르는 것은 이 사술의 한 칸이다.

현상이 표가 되는 순간

3 / 12

현상 → 표 흐름

현상 — "고객이 이탈한다"



개체(행) — 고객 한 사람



속성(열) — 가입기간·요금·이탈여부



표(DataFrame)

(n, p) — n개 행 × p개 열

세 가지 결정

1. 개체를 무엇으로 볼 것인가
2. 어떤 속성을 담을 것인가
3. 무엇을 맞힐 것인가

★ 모델 이전에 이 세 결정이
이후 전부를 규정한다.

잘못 정하면 생기는 결과

결정	잘못 정하면
개체를 무엇으로 볼 것인가	행의 의미가 섞여 모든 통계가 무의미해진다
어떤 속성을 담을 것인가	어떤 모델도 넘지 못하는 천장이 생긴다
무엇을 맞힐 것인가	문제 자체가 성립하지 않는다

자세한 열 구조는 다음 장에서

표의 해부 — 열은 곧 변수이고 피처다

열은 변수다 — 척도가 다르면 ML 이 다루는 방식도 다르다

4 / 12

구조 예시 — 행과 열의 역할

id	tenure	charge	contract	churn
C001	12	70.5	Month	0
C002	34	89.1	Two year	0
C003	2	99.9	Month	1
식별자	수치(비율)		범주(명목)	목표 y
버린다	X 로		인코딩	분리

행 = 고객 한 명(개체) · 열 = 변수

shape = (n, p+1)

★ id 는 버리고 churn 은 y 로 분리한다

숫자·문자와 무관하게 척도가 다루는 연산을 정한다

척도별 연산과 ML 취급

척도	가능한 연산	ML 에서의 취급
명목 · 순서	같다/다르다, 대소	★ 인코딩 — 열이 늘어난다
구간 · 비율	덧셈, 곱셈	수치 그대로 · 스케일 조정 대상


함정 — 숫자로 저장된 명목형

우편번호는 숫자로 저장돼도 명목이다.

평균을 내도 의미가 없는데 모델은 계산해 버린다.

X 와 y 를 가른다 — 문제의 종류가 정해진다

개념 — df 를 X 와 y 로 분리한다



df 의 마지막 열이 y, 나머지 모든 열이 X 다

y 의 성질별 문제 유형

y 의 성질	문제	배운 날
범주 2종 · 다종	분류	ML02 · ML03
연속 수치	회귀	ML04
y 가 없다	비지도 — 군집 · 차원축소	ML05

★ ML05 가 특별했던 이유가 여기 있다
y 열이 없으면 맞다·틀리다를 말할 수 없어 평가 방법 자체가 달라진다

정제 — 행과 열을 지우거나 값을 채운다

먼저 버릴 열 셋

식별자

고유값 개수가 표본 수 n 과 같다

상수 열

값이 하나뿐 — 정보량 0

누수 열

미래·정답 정보가 섞인 열

ID 판정은 글자 열에서만

연속 수치는 값이 거의 다 달라서 고유값 비율만 보면 ID 로 오인한다 — 실측에서 금액 열이 0.97 이었다.

결측 처리	모양	잃는 것
행 삭제	n 감소	개체 수 — 적은 데이터면 치명적
열 삭제	p 감소	변수 하나 통째
★ 대치	유지	분산 — 값이 평균으로 몰린다


★ 대치만 모양을 지킨다 — 대신 분산을 잃는다.

← 5. X 와 y 를 가른다

7. 분할이 변환보다 먼저다 →

분할이 변환보다 먼저다

구간부터 나눈다



★ 훈련에만 fit, 시험엔 transform만

변환 파라미터가 시험을 보면 정보가 샌다

한 번의 분할은 믿을 수 없다

— K겹 교차검증

종류	조작	언제
KFold	행을 K 등분	회귀 · 균형 잡힌 분류
Stratified KFold	각 겹의 클래스 비율을 원본과 같게 유지	분류 기본

불균형 데이터엔 K겹이 위험하다

KFold 사용 시 특정 겹에 소수 클래스가 0개일 수 있다 — 그 회차 점수는 무의미

⚠ 누수 — 순서가 정직성을 만든다

데이터 관점 ML 파이프라인 · 누수 방지

8 / 12

핵심 문제

test 의 평균·표준편차가 스케일러에 들어가는 순간
모델은 시험 문제를 미리 본 셈이 된다.

성능이 좋아 보이는 것이 문제다
— 배포하면 그 성능이 나오지 않는다.

잘못: 전체 (n, p) 로 fit → test 정보가 train 에 스며든다

옳음: 훈련 (n_{tr}, p) 로만 fit → 시험은 transform 만

→ 뒷장 (9/12): 변환 — 인코딩은 열을 늘리고 스케일링은 값을 바꾼다

잘못 vs 올바른

구분	잘못	올바름
순서	전체로 스케일러 fit → 분할	Pipeline 안에서 매 회차 train 으로만 fit
교차검증 점수	0.95 (거짓)	0.88 (진짜)

★ Pipeline 코드로 구조적 해법

```
Pipeline([("impute",...), ("encode",...),  
          ("scale",...), ("model",...)])
```

Pipeline 은 fit 이 호출되는 자리를
train 안쪽으로 자동 제한한다.

→ 앞장 (7/12): 분할이 변환보다 먼저다

변환 — 인코딩은 열을 늘리고 스케일링은 값을 바꾼다

09 / 12

개념

인코딩은 범주형 열 하나를 펼쳐 열 개수(p)를 늘린다
스케일링은 열 개수는 그대로 둔 채 값의 범위만 바꾼다

contract	원-핫	
Month	1	0
Two year	0	1

(n, 1) → (n, 2) ← 열이 늘었다 ★

★ (n, p) 의 p — 인코딩은 늘리고
스케일링은 그대로 둔 채 값만 바꾼다

스케일러 비교

변환기	수식	이상치에
StandardScaler	$(x - \text{평균}) / \text{표준편차}$	민감
MinMaxScaler	$(x - \text{최소}) / (\text{최대} - \text{최소})$	매우 민감
RobustScaler	$(x - \text{중앙값}) / \text{IQR}$	견고

★ 스케일 필요


KNN · SVM · 로지스틱회귀
K-평균 · PCA — 거리·계수 사용

스케일 불필요

결정트리 · 랜덤포레스트
분기점만 사용 — 스케일 무관

다음 → 축소 두 방향

축소의 두 방향 — PCA 는 열을 줄이고 군집은 열을 더한다




구분	얻는 것	잃는 것
PCA	열 수 감소 · 중복 제거 · 시각화	해석력 — PC1 은 이름이 없다
군집	y 가 없던 표에 y 비슷한 열을 만든다	정답이 없어 《옳음》을 증명 못 한다

★ 둘 다 스케일에 민감하다. 거리와 분산으로 세상을 보기 때문이다.
이것이 ML03 과 ML05 를 잇는 지점이다.

기법과 평가 — 함수를 얻고 두 벡터를 비교한다

핵심 흐름 — fit 으로 함수를 얻는다



★ 모든 기법은 fit 으로 함수를 얻고,
predict 로 새 입력에 적용한다는 점은 같다

⚠ 스케일 요구는 기법마다 다르다
— 회귀·K-평균·PCA 는 필요, 트리계열은 불필요

기법별 데이터 처리 방식과 스케일

기법	데이터에 하는 일	스케일
선형·로지스틱회귀	하나의 직선·평면으로 가른다	필요
결정트리·랜덤포레스트	축에 수직으로 자른다·다수결	불필요
K-평균·PCA	중심점·분산이 큰 방향	필요


문제 유형별 대표 지표와 함정

문제	대표 지표	함정
분류	정밀도·재현율·F1	⚠ 불균형이면 정확도에 속는다
회귀	MAE·RMSE·R ²	⚠ R ² 는 음수가 될 수 있다
군집	실루엣 계수	⚠ 잘 뭉쳤나를 잘 뿐 의미 있게 나뉘었나는 못 쟀다

활용 — 대안이 되거나 모듈이 된다

이전: 기법과 평가 — 함수를 얻고 두 벡터를 비교한다

파이프라인 → 산출



재현성 체크리스트

재현성 항목	왜
SEED = 42 고정	분할·초기화 난수 통일
스키마 기록	열 순서·dtype 불일치 시 오류
라이브러리 버전	squared=False 같은 인자 소실

⚠ 모델만 저장하면 안 된다

배포처에서 같은 전처리를 손으로 재현해야 하고, 조금이라도 달라지면 성능이 조용히 무너진다.

★ 데이터로 시작해 데이터로 답한다.

그 답이 유용할 때 비로소 대안이 되고, 반복될 때 모듈이 된다.