

ML 파이프라인 프레임워크

비즈니스 요구에서 남길 수 있는 결과물까지 — 4일 안에 관통하는 길


비즈니스 요구 → 5단계 13항목 → 운영 가능한 결과물

대상

ML00 ~ ML05 를 마친 수강생 · 4일 실습 프로젝트 전 기간

읽는 법

처음부터 읽지 않는다. 막힌 곳만 펴 본다



이 데스를 쓰는 법 — 어디가 막혔는가

순서대로 읽는 교재가 아니라 필요한 장을 골라 펴는 사전입니다.

지금 상황	펼 슬라이드
전체가 안 잡힌다	3 (5단계 한눈에)
무엇을 풀지 모르겠다	5 (문제 번역)
데이터를 방금 받았다	6 · 7 (첫 점검 · EDA)
점수가 좋은데 이상하다	8 · 9 (분할 · 누수)
점수가 안 오른다	12 → 11 → 14 (모델 → 특성 → 튜닝, 이 순서로)
무엇을 제출하나	16 · 17 · 20
우리 팀은 회귀·군집이다	19

5단계 13항목 — 한눈에

단계	언제	항목	끝났다는 뜻
1. 무엇을 풀 것인가	Day1 오전	1 문제번역 · 2 첫점검 · 3 EDA	목표 컬럼과 1순위 지표가 정해졌다
2. 기준선을 세운다	Day1 오후	4 분할 · 5 전처리설계 · 6 베이스라인	점수가 하나 찍혔다
3. 성능을 올린다	Day2	7 특성공학 · 8 모델탐색	베이스라인보다 나은 모델이 있다
4. 믿을 수 있는가	Day3	9 평가검증 · 10 튜닝	그 점수가 운이 아님을 보였다
5. 남길 수 있는가	Day4	11 해석 · 12 아티팩트 · 13 문서	남이 이어받을 수 있다

반드시 읽을 네 가지

- 1. 4번(분할)이 5번(전처리)보다 위 — 바꾸면 누수
- 2. 6번(베이스라인)이 7번보다 먼저 — 기준선 없이 “좋다”는 없다
- 3. 되돌아가는 길이 셋 있다 — 직선이 아니라 순환이다
- 4. 항목마다 넘기는 것이 있다 — 다음이 못 받으면 미완이다

★ Day1 끝에 점수가 안 나오면 일정이 이미 무너진 것입니다.

파이프라인이 받는 것 — 비즈니스 요구

받아야 할 것	없으면
질문 1문장	무엇을 맞는지 모른 채 돌린다
그 답으로 할 행동	점수는 오르는데 쓸 데가 없다
예산·계약	200명만 연락되는데 전체를 예측한다

절대 어기면 안 되는 6가지

#	규칙	어기면
0	ID·상수 컬럼을 먼저 버린다	원-핫 수백 컬럼이 되어 모델이 죽는다
1	분할을 전처리보다 먼저	누수 — 오류 없이 점수만 오른다
2	전처리는 Pipeline 안에	교차검증·저장·재현이 어긋난다
3	베이스라인을 먼저 켜다	"정확도 85%"가 좋은지 모른다
4	학습·검증 점수를 함께 본다	과적합을 진단할 수 없다
5	Day1 끝에 점수가 나와야 한다	4일이 이미 무너진 것이다

[1단계] 1. 문제 번역 — 질문을 ML 문제로

결정	무엇을 보고 정하는가
ML 문제인가	규칙으로 풀리면 쓰지 않는다
문제 유형	목표 컬럼의 정체로 갈린다
평가지표	틀렸을 때 누가 얼마나 손해인가

목표 컬럼(y) 없다 → 군집화 [ML05]
있다 ┆ 연속 숫자 → 회귀 [ML04]
┆ 범주 → 분류 [ML02·ML03] 2가지=이진분류 / 3가지+=다중분류

⚠ 이탈 27% 데이터에서 전부 "아니오"로 찍으면 **정확도가 73점**입니다. [ML02-H06 · S54]

[1단계] 2. 데이터 첫 점검 — 세 가지만 먼저

| 첫 점검 3가지

#	보는 것	명령	왜
1	크기·타입	df.shape	행 100개면 딥러닝 포기
2	결측	df.isna().sum()	처리 방식이 갈린다
3	목표 분포	df[목표].value_counts()	불균형이면 지표가 달라진다

| 바로 잘라낼 것

발견	조치
상수 컬럼	삭제 — 정보가 0
글자 컬럼인데 고유값이 행 수와 비슷	★ 삭제 — 안 지우면 외운다
수치 컬럼인데 고유값이 많다	⚠ 자동 삭제 금지
목표 컬럼이 결측	그 행 삭제
결과를 알아야 생기는 컬럼	★ 삭제 — 누수다

⚠ 실측 고유값 비율만 보고 지웠더니 금액 컬럼 2개가 사라졌다
(연속 수치는 0.92~0.97). ID 판정은 글자 컬럼에만.

[1단계] 3. EDA — 모델 이전에 눈으로 본다

네 장만 그린다

- ① 수치 히스토그램
- ② 목표 상관 순위
- ③ 결측 패턴
- ④ 범주 값 개수

발견 → 조치

보이는 것	뜻	조치
한쪽으로 쏠림	치우친 분포	log1p 검토 [ML04-H03 · S23]
범위가 100배 이상 차이	스케일 문제	표준화 [ML03-H02 · S11]
상관 0.95 이상	중복 정보	하나 제거
목표 분포 9:1 이상	불균형	지표 재검토 · stratify
⚠️ 상관 0.99 이상	누수 의심	생성 시점 확인

⚠️ "해지일자"로 "해지여부"를 맞히는 것은 예측이 아닙니다.
[ML02-H04 · S39]

[2단계] 4. 분할 — ★ 여기서 갈라야 한다

★ 이 항목이 관문입니다. 테스트셋은 아직 오지 않은 미래라, 전처리를 먼저 하면 그 정보가 학습에 스며들어 오류는 안 나는데 점수만 오릅니다.

```
X_tr, X_te, y_tr, y_te = train_test_split(
X, y, test_size=0.2, random_state=42, stratify=y) ★ 둘 다 필수
```

상황	방법
일반 분류	층화 분할 stratify=y
회귀	단순 분할
★ 시계열	시간순 분할 — 무작위는 미래로 과거를 맞힌다
같은 사람이 여러 행	GroupShuffleSplit

[2단계] 5. 전처리 설계 — 반드시 Pipeline 안에

Pipeline 을 쓰는 이유는 성능이 아니라 안전입니다

[ML03-H02 · S18]

학습셋은 `fit_transform` (기준을 배우고 적용), 테스트셋은 `transform` (배운 기준을 적용만).

누수 5종 — 오류가 안 나서 더 무섭다

유형	예	막는 법
전처리 누수	전체로 스케일러 fit 후 분할	Pipeline + 분할 먼저
컬럼 누수	"해지일자"로 "해지여부"	생성 시점 확인
시간 누수	미래로 과거 예측	시간순 분할
중복 누수	같은 사람이 양쪽에	GroupKFold
타깃 누수	타깃으로 만든 파생	파생 로직 검토

⚠ ColumnTransformer 는 지정 안 한 컬럼을 조용히 버립니다.
남는 컬럼이 없는지 `assert` 로 확인하십시오.

[2단계] 6. 베이스라인 — "이것보다 나은가"의 기준

베이스라인 정의

분류: DummyClassifier(strategy="most_frequent") · 회귀: DummyRegressor(strategy="mean")

베이스라인 없이 "정확도 85%"는 아무 뜻이 없습니다.

[ML02-H06 · S54]

실측 — boston 506행 · 5-fold CV

단계	MAE	R ²	소요
베이스라인	6.8189	-0.0106	0.05초
Day1 선형회귀	3.4284	0.7185	0.04초
Day3 랜덤포레스트	2.3973	0.8304	3.15초
Day3 HistGB	2.3841	0.8365	0.92초

★ 선형회귀 한 줄이 개선폭의 76%. 나머지 사흘이 24%를 다룹니다.
★ HistGB는 랜덤포레스트보다 성능도 낮고 3.4배 빠릅니다.

[3단계] 7. 특성 공학 — 모델보다 특성이 이긴다

좋은 특성의 조건 4가지

[ML02-H02 · S17]

- ① 목표와 관계가 있다
- ② 예측 시점에 알 수 있다
- ③ 지나치게 겹치지 않는다
- ④ 값이 안정적이다

특성 유형별 예시

유형	예	코드
비율	월요금 ÷ 총요금	<code>df["a"] / (df["b"] + 1e-9)</code>
구간화	나이 → 연령대	<code>pd.cut(...)</code>
집계	고객별 평균	<code>groupby(...).transform("mean")</code>
로그	치우친 금액	<code>np.log1p(...)</code>

⚠ 집계 파생은 학습셋만으로.

PCA는 표준화 뒤에 쓰되, 해석이 중요하면 쓰지 마십시오 — 주성분에는 이름이 없습니다.

[3단계] 8. 모델 탐색 — 순서가 정해져 있다

모델 탐색 순서

- ① 로지스틱 / 선형회귀 — 빠르고 해석 가능. 새 베이스라인
- ② 랜덤포레스트 — 대개 무난. 스케일 무관
- ③ HistGradientBoosting — 보통 가장 좋음
- ④ KNN · SVM (선택) — 스케일 필수
- ⑤ Voting (선택) — 다양성이 있을 때만

재는 것	왜
cv 평균	성능
cv 표준편차	폴드마다 흔들리면 믿을 수 없는 점수
소요 시간	1코어 환경이다

⚠ 점수가 안 오를 때의 순서는 모델 교체 → 특성 공학 → 튜닝.

튜닝을 먼저 하면 얻는 것이 가장 적습니다. [ML03-H06 · S59]

[4단계] 9. 평가·검증 — 무엇을 보고 판정하는가

혼동행렬 (TN/FP/FN/TP)

	예측 음성		예측 양성	
	예측 음성		예측 양성	
실제 음성	TN		FP (헛다리)	
실제 양성	FN (놓침)		TP	

정밀도 · 재현율 · F1 정의

정밀도 = $TP / (TP + FP)$ — 헛다리 비용이 클 때

재현율 = $TP / (TP + FN)$ — 놓침 비용이 클 때

F1 = 둘의 조화평균

predict_proba + 임계값 조정 코드

(0.5는 기본값일 뿐, 0.3~0.7 옮기)

```
확률 = 파이프라인.predict_proba(X_te)[: , 1]
```

```
# 0.5는 그냥 기본값일 뿐이다
```

```
예 = (확률 > 임계값).astype(int)
```

```
# 임계값을 0.3~0.7로 옮긴다
```

★ 재현율이 부족하면 모델을 바꾸기 전에
임계값부터 내려 보십시오. 공짜입니다.

회귀는 MAE·RMSE· R^2 + 잔차 그림,
군집은 실루엣 + 프로파일 표입니다.

[4단계] 10. 튜닝 — 마지막에, 시간을 계산하고

GridSearchCV 코드 예시 (파이프라인단계이름__파라미터)

```
격자 = {"모델__n_estimators": [100, 300]} # ★  
〈파이프라인단계이름〉__〈파라미터〉 탐색 =  
GridSearchCV(파이프라인, 격자, cv=cv,  
scoring="f1", n_jobs=1)
```

방법	언제
GridSearchCV	후보가 적을 때 (< 50조합)
RandomizedSearchCV	후보가 많을 때

★ 조합 수 × cv 만큼 학습합니다.

$2 \times 3 \times 2$ 격자 × cv5 = 60회. 1코어이므로 n_jobs=1.

⚠ 짜낼 것이 없다면 피처가 부족한 것 → 슬라이드 11 로 되돌아갑니다.

넘기는 것 → best_params_ + 학습된 최종 Pipeline [원본 §10]

[5단계] 11. 해석·오류 분석 — 왜 그렇게 예측했는가

방법	재는 것	주의
feature_importances_	학습 시 분할 기여	값 다양한 컬럼 과대평가
permutation_importance	테스트셋에서의 손해	느리지만 신뢰도 높음
회귀 계수	1 증가 시 y 변화	단위 다르면 비교 불가

오류 분석 — 배점 10점 [계획서 §7]

```
틀린것 = X_te[예측 != y_te]
틀린것[수치컬럼].mean() - X_te[수치컬럼].mean()
# 틀린 것들의 공통점
```

★ "성능 0.82"보다 "이런 고객에서 자주 틀린다"가 점수가 높습니다.

⚠ 상관이 강한 컬럼끼리는 중요도가 두 방법 모두 왜곡됩니다.

[5단계] 12. 아티팩트 — 남이 쓸 수 있게 만든다

joblib.dump / load — 전처리 포함 전체 저장·복원 검증

```
joblib.dump(최종, "artifacts/model.joblib") # ★ 전처리 포함 <전체>
복원 = joblib.load("artifacts/model.joblib") # ★ 저장했다고 되는 게 아니다
assert (복원.predict(X_te) == 최종.predict(X_te)).all()
```

재현성 규약 7항목 [계획서 §8.3] — 이 일곱 줄이 전부입니다

#	규약	#	규약
1	난수 시드 고정 (SEED = 42)	5	노트북은 순차 실행
2	데이터 분할을 파일로 저장	6	전처리는 Pipeline 내부
3	절대경로 금지	7	실험은 runs.csv 에 기록
4	버전을 requirements.txt 에 고정		

매 실험 직후 한 줄씩. 4일째에 기억으로 복원하려 하면 못 합니다.

[5단계] 13. 문서·발표 — 한계까지 적는다

필수 산출물 6종 [계획서 §6.2] — 이 여섯 줄이 제출물의 전부입니다

#	산출물	무엇이 들어가는가
1	README.md	문제 정의 · 실행 방법 · 구조
2	최종 노트북	클린 런타임에서 무오류 실행
3	model.joblib	전처리 포함 Pipeline 전체
4	schema.json	입력 컬럼 · 타입 · 허용 범위
5	predict.py	predict(payload) -> dict
6	model_card.md	용도 · 성능 · 사용 금지 상황

★ 배점은 성능 12점, 재현성·해석·문서 28점 [계획서 §7]. model_card.md 에는
"X 가 a~b 범위일 때만 유효" 를 적으십시오
(슬라이드 19의 외삽 사고)

넘기는 것 → 산출물 6종 + 한계 서술 = 운영 가능한 결과물

되돌아가는 세 갈래 — 파이프라인은 직선이 아니다

18 / 21

13항목을 한 번 훑고 끝나지 않습니다. 되돌아가는 길은 셋입니다.

#	어디서 어디로	언제
①	10 튜닝 → 7 특성공학	짜낼 것이 없다. 피처가 부족한 것이다
②	9 평가 → 1 문제번역	점수는 오르는데 현업이 원하는 것이 아니다
③	11 해석 → 3 EDA	특정 구간에서만 실패한다. 데이터를 다시 본다

CRISP-DM 이 30년간 순환 구조인 이유입니다

[ML02-H04 · S32]

비즈니스 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 배포 ↻

초급자의 가장 큰 실수는 모델링부터 시작하는 것입니다.

★ 4일뿐이라 되돌아갈 횟수는 한두 번. 그래서 Day1 의 정의가 중요합니다.

유형별로 《어려운 날》이 다르다

	분류 팀	회귀 팀	군집 팀
가장 어려운 날	Day3 (불균형·임계값)	Day2 (목표변수 분포)	Day1 (정답이 없다)
고유 함정	정확도 착시	외삽 · 이상치	실루엣 맹신
최종 산출	혼동행렬 + 임계값 근거	잔차 그림 + 예측구간	군집 프로파일 표

회귀 — 외삽에서 선형과 트리가 《정반대로》 틀린다

[ML04-H05 · S43]
학습 범위 최대 8.78 · 질의 13.17 · 학습 y 최대 50

모델	예측	무슨 일이
랜덤포레스트	31.11	범위 밖이라 끝 값에 갇힌다
선형회귀	85.20	직선을 늘려 폭주한다

둘 다 틀렸는데 틀리는 방식이 반대입니다.

★ 군집 — 엘보우는 k=4~5, 실루엣은 k=6.

다른 답이 정상입니다.

군집 2·3은 소득이 같은 86.1 인데

지출은 81.5 대 19.4 였습니다.

4일 일정과 그날 끝에 있어야 할 것

4일 운영	항목	원본	그날 끝에 있어야 할 것
Day 1 문제정의·데이터	1·2·3·4·6	§1~§6	★ 점수가 찍힌 노트북 1개
Day 2 파이프라인·특성공학	5·7	§5 §7	베이스라인보다 나은 모델
Day 3 모델탐색·튜닝·평가	8·9·10	§8 §9	모델 비교표 · 혼동행렬
Day 4 해석·아티팩트·문서	11·12·13	§10~§12	산출물 6종 · 발표자료

제출 전 자가 점검

슬라이드 17 이 《무엇을 내는가》라면 여기는 《제대로 됐는가》입니다

- ☐ 클린 런타임에서 노트북이 무오류로 돈다
- ☐ 저장한 모델을 불러 예측이 같음을 assert 로 확인했다
- ☐ schema.json 에 허용 범위가 있다
- ☐ model_card.md 에 《사용 금지 상황》이 있다
- ☐ runs.csv 에 실험 기록이 있다
- ☐ 베이스라인 점수와 최종 점수를 나란히 낼 수 있다